

Spaceship Titanic 数据组成清单

基于你上传的 train.csv、test.csv、sample_submission.csv 生成，用于快速建立对数据结构、字段含义与预处理重点的整体认知。

任务类型	训练样本	测试样本	标签分布
二分类	8693	4277	True 4378 / False 4315

一、数据文件概览

文件	行数	列数	用途	备注
train.csv	8693	14	训练模型；包含标签 Transported	本次建模的主数据源
test.csv	4277	13	生成预测结果；不含标签	需与训练集做同口径预处理
sample_submission.csv	4277	2	提交格式模板	字段为 PassengerId + Transported

二、字段组成（第 1 部分）

字段	角色 / 含义	训练集缺失率	测试集缺失率	示例值
PassengerId	乘客编号，形如 0003_02；可拆 GroupId 与组内序号	0.0%	0.0%	0001_01 / 0002_01
HomePlanet	出发星球，低基数分类特征	2.31%	2.03%	Europa / Earth
CryoSleep	是否冷冻休眠，与消费列强相关	2.5%	2.17%	False / False
Cabin	舱位，形如 B/0/P；可拆 Deck / CabinNum / Side	2.29%	2.34%	B/0/P / F/0/S
Destination	目的地星球，低基数分类特征	2.09%	2.15%	TRAPPIST-1e / TRAPPIST-1e
Age	年龄，连续数值	2.06%	2.13%	39.0 / 24.0
VIP	是否为 VIP，二值但分布极不均衡	2.34%	2.17%	False / False

三、字段组成（第 2 部分）

字段	角色 / 含义	训练集缺失率	测试集缺失率	示例值
RoomService	客房服务消费	2.08%	1.92%	0.0 / 109.0
FoodCourt	餐饮消费	2.11%	2.48%	0.0 / 9.0
ShoppingMall	购物消费	2.39%	2.29%	0.0 / 25.0
Spa	水疗消费	2.11%	2.36%	0.0 / 549.0
VRDeck	VR 娱乐消费	2.16%	1.87%	0.0 / 44.0
Name	姓名；可提取姓氏、家庭信息	2.3%	2.2%	Maham Ofracculy / Juanna Vines
Transported	目标变量，是否被传送	0.0%	—	False / True

四、这份数据集最值得记住的结构特征

结构主题	数据事实	对预处理的启发
群组关系	PassengerId 前半段是组号；训练集中约有 6217 个组，平均每组 1.4 人，最大 8 人。	建议构造 GroupId、GroupSize、组内序号等特征
舱位信息	Cabin 可拆成 Deck / CabinNum / Side；Deck 以 F(2794)、G(2559) 最多；Side 约均衡（S 4288 / P 4206）。	不要把 Cabin 当普通字符串直接喂给模型
消费特征	五项消费大量为 0，且分布明显右偏；适合构造 TotalSpend、IsZeroSpend、AnySpendPositive。	树模型可直接用原值；线性模型可考虑 log1p 变换
缺失模式	多数列缺失率约 2% 左右，范围不大但分布在多列。	更适合精细填补，而不是简单删行
标签分布	Transported=True 4378 (50.36%)，False 4315 (49.64%)。	类别较均衡，一般不需要重采样

五、后续写 preprocess.py 时的检查清单

优先级	建议重点检查	原因
高	PassengerId、Cabin、CryoSleep、五项消费	这里包含最强的结构信息与业务逻辑
中	HomePlanet、Destination、Age、VIP	是常规强特征，适合直接进入建模流程
中	Name	可提取姓氏或与组关系联合使用
执行顺序	统一读入 train/test → 字段拆分 → 缺失值处理 → 消费汇总特征 → 编码 → 按模型需要做标准化	便于后续把 preprocess.py 与 main.py 解耦

六、字段分层的快速记忆方式

分层类别	字段
标识 / 可拆结构	PassengerId、Cabin、Name
低基数分类	HomePlanet、CryoSleep、Destination、VIP、Deck、Side
连续数值	Age、CabinNum、RoomService、FoodCourt、ShoppingMall、Spa、VRDeck、TotalSpend
目标变量	Transported

七、一句话理解这份数据

建议你这份数据集先理解成一张“带群组关系的乘客行为表”：PassengerId 负责告诉你谁和谁同行，Cabin 负责告诉你乘客位于船的什么位置，CryoSleep 与五项消费共同描述乘客状态和行为，HomePlanet / Destination / VIP / Age 则提供个人属性背景。