

Spaceship Titanic 项目

模型选择决策参考（基础说明增强版）

适用场景：组内模型路线审阅、任务分工讨论、模型投票决策
阅读建议：先看“方案选择对比表”，再看“模型基础说明表”和“核心候选模型表”。

- 本项目是中小规模表格型二分类任务，主力一般优先考虑 boosting 与类别友好模型，而不是深度学习主线。
- 最平衡的核心 4 模型建议：Logistic Regression、Random Forest、XGBoost / LightGBM、CatBoost。
- 若时间允许，可在后期增加 Soft Voting / Weighted Voting；不建议一开始就上复杂 Stacking。
- 若组内需要先做快速投票，建议优先考虑“方案 A 增强版”。

一、模型基础说明表

这一部分用于帮助非负责该模型的组员快速理解“模型本质是什么、它为什么可能适合这个项目、实现时大概会碰到什么问题”。

模型	一句话基础理解	它在这个项目里通常负责什么	上手难度	典型注意点
Logistic Regression	线性分类模型：通过学习一组权重，把特征线性组合后做二分类判断。	最适合做 baseline 和流程校验，也方便解释哪些特征方向更重要。	低	通常需要标准化；对复杂非线性关系表达有限。
Random Forest	多策做 bagging 集成：每棵树看数据的不同子样本，最后投票。	适合作为“树模型强基线”，帮助判断非线性关系是否明显存在。	低-中	通常不需要标准化；编码方式会影响效果；上限常低于 boosting。
HistGradientBoosting	基于梯度提升思想逐步修正前一轮错误，并用直方图方式加速训练。	适合作为 boosting 入版本，便于在 sklearn 体系内快速比较。	中	需要较干净的编码输入；类别特征支持不如 CatBoost 自然。
XGBoost	经典 boosting 树模型：不断叠加新树去纠正当前误差，强调性能与正则化。	常作为主力冲分模型之一，适合系统调参与特征工程。	中-高	参数多；类别特征通常要自己编码；实验记录要清楚。
LightGBM	也是 boosting 树模型，但训练速度通常更快，常适合快速迭代。	适合作为主力模型或与 XGBoost 做二选一比较。	中-高	对特征处理较敏感；小数据上未必总胜过 CatBoost。
CatBoost	面向类别特征更友好的 boosting 模型，能更自然地处理类别变量。	非常适合当前这类“混合特征 + 缺失值 + 类别字段较多”的表格任务。	中	虽然预处理更省力，但仍需要认真做参数与版本管理。
Decision Tree	按不切分特征空，最后出分类结果。	适合作为原型模型或展示“为什么单树容易过拟合、为什么需要集成树”。	低	容易合，通常不合作最主力。
Extra Trees	与随机森林相近，但划分更随机，因此训练快、随机性更强。	可作为 RF 的补充对照模型。	中	表不一定定于 RF，更多是补充。
Linear SVM / SVC	支持向量机通过寻找一个最优分类边界把两类样本分开。	适合增加模型家族多样性，做“非树模型”补充。	中	准化重要；one-hot 后高维输入时效率与收益可能一般。
KNN	不显式训练复杂模型，而是看“离我最近	适合作为距离类方法的直观对照。	低-中	高维 one-hot 后容易受限，预测速度也较

	的样本大多属于哪一类”。			慢。
Naive Bayes	基于概率分解并假设特征相互独立来做分类。	适合极简对照，不适合作为主力。	低	立性假太强，在表格任上通常较弱。
AdaBoost	早期经典 boosting 方法，逐步提高前面分错样本的权重。	可用于补足“boosting 家族”的教学展示。	中	实战效果通常不如 XGBoost / LightGBM / CatBoost。
MLP / 简单神经网络	多层全连接网络，通过非线性变换学习分类边界。	可增加方法覆盖面，但更偏补充而非主线。	中-高	对表格中小数据常不如 boosting 稳定，调参成本更高。
TabNet / 自写 DL	更复杂的深度学习表格模型，强调自动学习特征表示。	研究味更强，适合在时间很多且有人熟悉 DL 时尝试。	高	投入大、收益不稳定，不适合作为当前默认路线。
Voting / Stacking	不是单独模型，而是把多个单模型结果再组合。	适合放在最后做冲榜或稳分。	中-高	前提是单模型已经稳定；stacking 必须防数据泄漏。

二、核心候选模型表

这部分是最值得投入的模型。新增“基础理解”列，便于组员在投票时快速把模型原理和项目价值联系起来。

模型	难度	基础理解（简洁版）	预处理要求	主要优点	主要局限	项目适配度	建议定位
Logistic Regression	低	线性模型，用一条“加权和边界”做分类。	缺失值填补；类别编码；数值标准化	训练快、可解释、适合作为 baseline；便于验证整套 pipeline 是否正确	难以捕捉复杂非线性关系；通常不是最终最强分数	高	必做 baseline
Random Forest	低-中	多棵随机决策树投票，属于 bagging 集成。	类别编码即可；通常不要求标准化	树模型强基线；非线性能力明显强于线性模型；容易做特征重要性分析	上限通常不如 boosting；特征交互表仍有限	高	建做
HistGradientBoosting	中	boosting 树模型的高效实现，逐步修正错误。	缺失值处理；类别编码；一般不需要标准化	sklearn 体系内上手顺；比传统 GBDT 更高效；很适合做 boosting 入门版本	类别特征支持不如 CatBoost；上限常略低于调好的 XGBoost / LightGBM	高	可作为备选主力
XGBoost	中-高	经典 boosting 主力模型，靠不断加树纠错来提升性能。	缺失值处理；类别编码；较完整特征工程	表格任务经典强模型；资料多；表现稳定；适合系统调参	参数较多；编码与调参成本较高	很高	强烈推荐
LightGBM	中-高	高效 boosting 树模型，通常更快，适合快速迭代。	缺失值处理；类别编码；较完整特征工程	训练速度快；调参效率高；在表格任务中经常表现优秀	小数据集不一定于 CatBoost；类别处理要更谨慎	很高	强烈推荐
CatBoost	中	对类别特征很友好的 boosting 模型。	类别特征可较自然地输入；缺失值处理压力较小	对类别变量和缺失值都友好；非常适合本项目这类混合特征表格数据；经常是主力模型	想调到最好仍需版本管理与实验记录	高	最推荐主力

三、扩展候选模型表

这些模型不是当前最优先投入方向，但在需要增强“模型多样性”或补足组员分工时仍可考虑。新增“基础理解”列以帮助快速判断是否值得投入。

模型	难度	基础理解（简洁版）	预处理要求	可用价值	主要风险 / 缺点	适配度	建议
Decision Tree	低	单棵树按规则切分样本。	类别编码；一般不要求标准化	单树规则直观，适合作为树模型原型或展示“为什么要走向集成树”	极易过拟合；单模型上限低	中	可做但不主打
Extra Trees	中	更随机的树集成，可视为 RF 的近亲。	与 Random Forest 类似	可作为 RF 的补充树模型；有时训练更快	果不一定定于 RF；解释性略弱	中-高	有余力可做
Linear SVM	中	通过最大化分类间隔来做线性分类。	缺失值处理；类别编码；通常需要标准化	可作为另一种线性模型对照	通常不如树模型 / boosting 值得投入	中	可选
SVC（核 SVM）	中	用核技巧学习更复杂的非线性边界。	标准化、编码、较干净输入	家族差异大，汇报上好讲	高维 one-hot 后效率与收益往往一般；训练更慢	中	不优先
KNN	低-中	看最近本投票，不式学复杂参数。	缺失值处理；编码；强依赖标准化	原理直观，可展示距离类方法	高维 one-hot 后常受限；推理慢	中-低	不建议重点做

Naive Bayes	低	基于概率与条件独立假设做分类。	通常需数值化、较简洁输入	极快，可作极简对照模型	独立性假设过强；效果通常弱	低	不建议重点做
AdaBoost	中	逐步提高分错样本权重的经典 boosting。	较干净输入；常需较简洁特征	可补足 boosting 家族的展示	实战中通常被更强 boosting 模型替代	中-低	不建议重点做
MLP / 简单神经网络	中-高	多层全连接网络学习非线性分类边界。	缺失值处理；编码；标准化；训练流程更复杂	可增加方法覆盖面	对这类中小型表格任务常不如 boosting 稳定；调参耗时	中	非必要
TabNet / 自写 DL	高	更复杂的深度学习表格模型。	完整训练、验证、调参流程	研究味更强	投入大、收益不稳定；不适合当前阶段作为主线	中-低	不建议主线投入

四、后期集成策略表

集成方法适合放在单模型稳定之后再 做。它们不是替代单模型，而是在已有强单模型基础上的最后提升。

集成方式	基础理解（简洁版）	难度	前置条件	点	主要风险	是否建议
Soft Voting	把多个模型的预测概率做平均，再决定最终类别。	中	已有 2-3 个稳定单模型	实现简单；常能带来稳健提升；非常适合作为第一版集成	若模型差不足，提升有限	建议作为后期第一优先
Weighted Voting	和投票类似，但给更强模型更高权重。	中	已有可靠 CV 结果可分配权重	比普通投票更灵活；对冲榜单更实用	权重若只凭榜单直觉设置，容易过拟合	建议做
Stacking	把单模型输出再喂给一个“二层模型”做组合。	中-高	需保存 OOF 预测；需严格避免泄漏	上限可能更高；适合深入实验	流程更复杂；实现不严谨时风险最大	时间足够再做
Blending	留出一部分数据，专门用来学习多个模型的组合。	中	需保留专门 holdout 集	实现比 stacking 略简单	浪费训练数据；提升不一定明显	一般不优先

五、方案选择对比表

如果需要直接在组内投票，这一页就是最核心的决策区域。建议先定方案，再定第三主力模型具体选 XGBoost 还是 LightGBM。

方案	模型组成	主要优点	主要风险 / 短板	适用情形	推荐度
方案 A（稳妥标准）	Logistic Regression + Random Forest + XGBoost/LightGBM + CatBoost	结构完整；课程汇报很好讲；难度合理；兼 baseline、树模型和 boosting 主力	后期若想进一步冲榜，还需要再补一个集成步骤	大多数小组的最优默认方案	★★★★★
方案 A 增强版	方案 A + Voting / Weighted Voting	在保持结构清晰的前提下，再增加后期冲榜能力；课程与 Kaggle 两端都更平衡	需要单模型结果先稳定下来，再做集成	最推荐的最终路线	★★★★★
方案 B（偏冲分）	Logistic Regression + LightGBM + XGBoost + CatBoost + Voting	更偏 Kaggle 实战；主力模型更强；后期自然过渡到集成	两个 boosting 模型家族相近，报告里要讲清楚差异，避免显得重复	组内有人熟悉 boosting 调参	★★★★☆
方案 C（偏多样性）	Logistic Regression + Random Forest + SVM + CatBoost + Ensemble	模型家族差异更大；展示时更有“多模型比较”感	实战分数不一定优于方案 A / B；SVM 性价比一般	更重视课程展示而非榜单	★★★☆☆
方案 D（不建议）	深度学习主线 / 复杂 stacking 主线	研究感强	时间成本高；收益不稳定；当前阶段会分散主力	仅做明确时常常充裕考虑	★☆☆☆☆

六、总结

总结维度	建议
------	----

核心 4 模型	Logistic Regression、Random Forest、CatBoost、XGBoost/LightGBM（二选一）
最值得重点投入	CatBoost；它对类别特征更友好，也更适合当前这类中小规模混合型表格数据
若时间有限	优先保证 CatBoost + 1 个 Boosting 模型 + Logistic Regression baseline，不建议把时间过多投入冷门模型
后期冲榜路线	在单模型 CV 结果稳定后，再加入 Soft Voting 或 Weighted Voting；不建议一开始就做复杂 stacking

一句话推荐：如果组内想在课程要求、实现成本与 Kaggle 实战价值之间取得平衡，最推荐的路线仍然是“方案 A 增强版”：先完成 Logistic Regression、Random Forest、XGBoost/LightGBM、CatBoost 作核心 4 模型，再在单模型稳定后补做 Voting / Weighted Voting。